

Prompt-CAM을 이용한 식물의 분류학적 계층 모델

1 서론

1.1 연구 배경 및 목적

식물의 fine-grained 분류에서는 서로 가까운 종이 전체적인 외형보다 국소적인 형질에 의해 구분되는 경우가 많다. 입력 사진에 해당 형질이 충분히 나타나지 않으면 종 수준의 판별 근거가 부족할 수 있으며, 이때 모든 입력을 하나의 종으로 강제 분류하는 방식은 모델의 불확실성을 적절히 표현하지 못한다. 사유원 캡스톤 프로젝트와 현장 식물 동정 자문에서도 사진만으로 종을 확정하기 어렵고 속 또는 과 수준까지만 판단 가능한 사례가 많았다.

이 문제를 다루기 위해 과-속-종의 분류 체계를 Prompt-CAM의 표현과 확률 모델에 직접 반영하였다. 목표는 하나의 모델에서 과-속-종 각 단계의 확률과 시각적 근거를 함께 계산하고, 종 수준의 확신이 충분하지 않을 때에는 해당 종이 속한 속이나 과까지 범위를 넓혀 답할 수 있도록 하는 것이다. 이를 통해 fine-grained 분류의 성능뿐 아니라 분류 단계별 시각적 근거와 계층적 확률의 일관성을 함께 분석한다.

2 제안 방법

Prompt-CAM은 클래스마다 학습 가능한 prompt token을 두고, 각 prompt token이 이미지의 여러 패치와 attention을 계산하여 분류 점수와 시각적 근거를 함께 얻는 방법이다. 이 구조를 과-속-종의 분류 체계로 확장한 계층적 Prompt-CAM을 제안한다. 식물 사진 한 장이 들어오면 어느 과에 속하는지, 그 과 안에서 어느 속에 속하는지, 마지막으로 그 속 안에서 어느 종에 속하는지를 순서대로 판단하고, 각 판단 단계에서 이미지의 어느 부분을 근거로 사용했는지도 함께 계산한다.

예를 들어 정답이 참느릅나무인 사진이라면 모델은

느릅나무과 → 느릅나무속 → 참느릅나무

라는 하나의 분류 경로를 평가한다. 종까지 구분할 근거가 충분한 경우에는 참느릅나무를 답할 수 있고, 종 수준의 확률이 충분하지 않은 경우에는 같은 경로의 상위 분류군인 느릅나무속 또는 느릅나무과를 반환할 수 있다. 아래에서는 이 계산이 어떻게 이루어지는지를 순서대로 설명한다.

2.1 실험 데이터셋 및 분류 체계

실험을 위해 iNaturalist에 공개된 자연 관찰 이미지 중 30개 식물 종을 선정하고, 각 종의 이미지를 수집·정리하여 데이터셋을 구성하였다. 또한 각 종이 속하는 속과 과를 함께 기록하여, 각 클래스가 “과 → 속 → 종”으로 이어지는 하나의 분류 경로를 갖도록 하였다.

이 데이터셋은 6개 과, 7개 속, 30개 종으로 구성된다. 각 종마다 400장의 이미지를 사용하여 전체 이미지는 12,000장이다. 종별로 학습 300장, 검증 50장, 테스트 50장을 사용하였으므로 전체 분할은 각각 9,000장, 1,500장, 1,500장이다.

과	속	선정 종
참나무과	참나무속	상수리나무, 굴참나무, 졸참나무, 신갈나무, 로부르참나무, 루브라참나무
무환자나무과	단풍나무속	단풍나무, 고로쇠나무, 신나무, 루브롬단풍나무, 설탕단풍, 노르웨이단풍
느릅나무과	느티나무속	느티나무
느릅나무과	느릅나무속	참느릅나무, 비술나무, 미국느릅나무, 위치느릅나무
삼과	팽나무속	팽나무
자작나무과	자작나무속	자작나무, 종이자작나무, 강변자작나무, 털자작나무, 노랑자작나무, 렌타자작
소나무과	소나무속	구주소나무, 스트로브잣나무, 폰데로사소나무, 로지폴소나무, 유럽흑송, 라디아타소나무

Table 1: 실험 데이터셋에 포함된 과, 속, 종의 분류학적 구성.

2.2 전체 계산 과정

입력 이미지는 DINOv2 ViT-B/14의 patch embedding을 통해 이미지 token으로 변환된다. 입력 크기는 336×336 이고 patch size는 14×14 이므로,

$$24 \times 24 = 576$$

개의 이미지 패치가 만들어진다. DINOv2 ViT-B/14의 embedding dimension은 768이므로 각 패치 token은 768차원 벡터로 표현된다.

본 연구에서는 이 이미지 token과 함께 과, 속, 종을 나타내는 prompt token을 Transformer에 넣는다. Prompt token은 이미지 token과 attention을 주고받으면서 각 분류 단계에 필요한 이미지 정보를 얻는다.

예를 들어 상수리나무를 분류할 때 모델은 하나의 이미지로부터

참나무과 → 참나무속 → 상수리나무

에 해당하는 세 단계의 판단을 동시에 수행한다. 과 단계에서는 참나무과를 다른 과와 구분하고, 속 단계에서는 참나무과 안에서 참나무속을 구분하며, 종 단계에서는 참나무속 안에서 상수리나무를 다른 종과 구분한다.

각 단계의 prompt token이 어떤 이미지 패치를 많이 사용했는지는 해당 단계의 Prompt-CAM으로 나타난다. 따라서 하나의 모델과 한 번의 추론으로 과·속·종의 예측과 각 단계의 Prompt-CAM을 함께 얻을 수 있다.

2.3 계층적 prompt token의 구성

기존 Prompt-CAM에서는 분류하려는 각 클래스에 별도의 prompt token을 둔다. 본 연구에서는 과, 속, 종을 서로 독립적인 클래스로 두는 대신, 분류 체계에서 공유되는 정보를 prompt token 자체에 반영한다.

아이디어는 과에서 속으로, 속에서 종으로 내려갈 때 이전 단계의 prompt token과 독립적인 새로운 prompt token을 만드는 것이 아니라, 하위 단계를 구분하기 위한 성분을 하나씩 추가한다.

과 f 의 prompt token을

$$\mathbf{q}_{F,f}^{(\ell)} = \mathbf{a}_f^{(\ell)}$$

로 둔다. 속 g 의 부모 과를 $\phi(g)$ 라 하면 속 prompt token은

$$\mathbf{q}_{G,g}^{(\ell)} = \mathbf{a}_{\phi(g)}^{(\ell)} + \mathbf{r}_g^{(\ell)}$$

로 구성한다. 마지막으로 종 c 의 부모 속을 $\gamma(c)$ 라 하면 종 prompt token은

$$\mathbf{q}_{S,c}^{(\ell)} = \mathbf{a}_{\phi(\gamma(c))}^{(\ell)} + \mathbf{r}_{\gamma(c)}^{(\ell)} + \mathbf{s}_c^{(\ell)}$$

로 구성한다.

따라서 세 단계의 관계는

과 :	$\mathbf{a}_f,$
속 :	$\mathbf{a}_f + \mathbf{r}_g,$
종 :	$\mathbf{a}_f + \mathbf{r}_g + \mathbf{s}_c$

로 요약할 수 있다.

예를 들어 참나무과, 참나무속, 상수리나무의 prompt token은 각각

$$\mathbf{q}_{F,참나무과} = \mathbf{a}_{참나무과},$$

$$\mathbf{q}_{G,참나무속} = \mathbf{a}_{참나무과} + \mathbf{r}_{참나무속},$$

$$\mathbf{q}_{S,상수리나무} = \mathbf{a}_{참나무과} + \mathbf{r}_{참나무속} + \mathbf{s}_{상수리나무}$$

가 된다.

같은 참나무속에 속하는 굴참나무는

$$\mathbf{q}_{S,굴참나무} = \mathbf{a}_{참나무과} + \mathbf{r}_{참나무속} + \mathbf{s}_{굴참나무}$$

이므로 두 종은

$$\mathbf{a}_{참나무과} + \mathbf{r}_{참나무속}$$

부분을 그대로 공유한다. 두 종을 구분하는 것은 마지막의

$$\mathbf{s}_{\text{상수리나무}} \quad \text{과} \quad \mathbf{s}_{\text{굴참나무}}$$

이다.

반면 단풍나무속의 종과 비교하면 속 성분부터 달라지고, 서로 다른과의 종과 비교하면 과 성분부터 달라진다. 즉 taxonomy에서 가까운 분류군일수록 prompt token의 더 많은 부분을 공유하도록 구성하였다.

간단한 예시 실제 모델에서는 각 프롬프트 토큰의 임베딩이 768차원이지만, 구조를 가장 단순하게 보기 위해 여기서는 임베딩 차원을 $d = 3$ 으로 줄인 toy example을 생각하자. 아래 숫자는 실제로 학습된 임베딩 값이 아니라 덧셈 구조를 설명하기 위한 값이다.

참나무과의 기본 성분을

$$\mathbf{a}_{\text{참나무과}} = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}$$

로 두고, 참나무속에서 추가되는 성분을

$$\mathbf{r}_{\text{참나무속}} = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$

로 두자. 그러면 참나무속 프롬프트 토큰의 임베딩은 두 성분을 더한

$$\mathbf{u}_{\text{참나무속}} = \mathbf{a}_{\text{참나무과}} + \mathbf{r}_{\text{참나무속}} = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}$$

가 된다. 이 예에서는 첫 번째 좌표가 과에서 공유되는 성분, 두 번째 좌표가 참나무속에서 추가되는 성분을 나타내도록 단순화하였다.

이제 상수리나무와 굴참나무를 구분하기 위한 종별 추가 성분을 각각

$$\mathbf{s}_{\text{상수리나무}} = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}, \quad \mathbf{s}_{\text{굴참나무}} = \begin{bmatrix} 0 \\ 0 \\ -1 \end{bmatrix}$$

로 두자. 그러면 상수리나무의 최종 프롬프트 토큰 임베딩은

$$\mathbf{v}_{\text{상수리나무}} = \underbrace{\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}}_{\text{참나무과}} + \underbrace{\begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}}_{\text{참나무속}} + \underbrace{\begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}}_{\text{상수리나무}} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$$

이고, 굴참나무는

$$\mathbf{v}_{\text{굴참나무}} = \underbrace{\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}}_{\text{참나무과}} + \underbrace{\begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}}_{\text{참나무속}} + \underbrace{\begin{bmatrix} 0 \\ 0 \\ -1 \end{bmatrix}}_{\text{굴참나무}} = \begin{bmatrix} 1 \\ 1 \\ -1 \end{bmatrix}$$

가 된다.

이 숫자 예에서는 두 종이 첫 번째와 두 번째 좌표를 완전히 공유하고, 세 번째 좌표에서만 달라진다. 실제로

$$\mathbf{v}_{\text{상수리나무}} - \mathbf{v}_{\text{굴참나무}} = \begin{bmatrix} 0 \\ 0 \\ 2 \end{bmatrix} = \mathbf{s}_{\text{상수리나무}} - \mathbf{s}_{\text{굴참나무}}$$

이다. 따라서 같은 속에 속하는 두 종은 과와 속에서 형성된 성분을 공유하고, 종별 추가 성분이 두 종의 차이를 만든다는 앞의 식을 숫자로 그대로 확인할 수 있다.

위와 같은 방법으로 활성 Transformer 층에서는 과 prompt token $\mathbf{a}_f^{(\ell)}$, 속 prompt token $\mathbf{u}_g^{(\ell)}$, 종 prompt token $\mathbf{v}_c^{(\ell)}$ 를 모두 삽입한다. 데이터셋에는 과 6개, 속 7개, 종 30개가 있으므로 한 활성 층에서 삽입되는 계층적 prompt token은

$$6 + 7 + 30 = 43$$

개이다.

2.4 Prompt token과 이미지 패치의 attention 계산

계층적으로 구성한 prompt token은 이미지 패치에서 얻은 정보를 이용해 각 분류군의 점수를 계산한다. 분류 단계 $r \in \{F, G, S\}$ 에서 분류군 n 의 prompt token을 $\mathbf{q}_{r,n}$, p 번째 이미지 패치를 $\mathbf{x}_p$ 라 하자. 입력 크기가 336×336 이고 patch size가 14×14 이므로 이미지에는 총 576개의 패치가 있다.

Attention head h 에서는 prompt token으로부터 query를 만들고, 각 이미지 패치로부터 key와 value를 만든다.

$$\mathbf{Q}_{r,n}^{(h)} = W_{Q,r}^{(h)} \mathbf{q}_{r,n}, \quad \mathbf{K}_{r,p}^{(h)} = W_{K,r}^{(h)} \mathbf{x}_p, \quad \mathbf{V}_{r,p}^{(h)} = W_{V,r}^{(h)} \mathbf{x}_p.$$

여기서 $W_{Q,r}^{(h)}$, $W_{K,r}^{(h)}$, $W_{V,r}^{(h)}$ 는 학습되는 행렬이다. Prompt token과 각 패치의 유사도는

$$e_{r,n,p}^{(h)} = \frac{\left(\mathbf{Q}_{r,n}^{(h)}\right)^\top \mathbf{K}_{r,p}^{(h)}}{\sqrt{d_h}}$$

로 계산하고, 이를 576개 패치에 대해 softmax하여

$$A_{r,n,p}^{(h)} = \frac{\exp\left(e_{r,n,p}^{(h)}\right)}{\sum_{j=1}^{576} \exp\left(e_{r,n,j}^{(h)}\right)}$$

을 얻는다. 따라서

$$\sum_{p=1}^{576} A_{r,n,p}^{(h)} = 1$$

이며, $A_{r,n,p}^{(h)}$ 가 클수록 해당 prompt token이 p 번째 패치의 정보를 더 많이 사용한다. 각 head에서 prompt token이 이미지로부터 읽어 오는 정보는

$$\mathbf{u}_{r,n}^{(h)} = \sum_{p=1}^{576} A_{r,n,p}^{(h)} \mathbf{v}_{r,p}^{(h)}$$

로 계산한다. 여러 head에서 얻은 값은

$$\tilde{\mathbf{q}}_{r,n} = \text{LN}\left(W_{O,r} \text{Concat}_{h=1}^H \left[\alpha_r^{(h)} \mathbf{u}_{r,n}^{(h)}\right]\right)$$

으로 합친다. 여기서 H 는 attention head의 개수이고, $\alpha_r^{(h)}$ 는 각 head에 주어지는 학습 가능한 가중치이다.

분류 단계 r 에 속하는 모든 분류군은 하나의 가중치 벡터 $\mathbf{w}_r$ 를 공유하며, 분류군 n 의 점수는

$$z_{r,n} = \mathbf{w}_r^\top \tilde{\mathbf{q}}_{r,n}$$

으로 계산한다.

기존 Prompt-CAM과 달리, 여기서는 최종 점수를 계산할 때 원래의 prompt token $\mathbf{q}_{r,n}$ 을 $\tilde{\mathbf{q}}_{r,n}$ 에 다시 더하지 않는다. 따라서 분류에 직접 사용되는 것은 prompt token 자체가 아니라, prompt token이 이미지 패치에서 읽어 온 정보이다.

각 패치의 CAM 값은

$$\text{CAM}_{r,n,p} = \sum_{h=1}^H \alpha_r^{(h)} A_{r,n,p}^{(h)}$$

로 계산한다. 따라서 $\text{CAM}_{r,n,p}$ 는 분류군 n 의 점수를 계산할 때 p 번째 이미지 패치가 얼마나 사용되었는지를 나타낸다.

2.5 과-속-종 경로 확률

각 과, 속, 종에 대한 점수 $z_{r,n}$ 을 얻은 뒤에는 이를 분류 체계에 따라 조건부 확률로 변환한다. 과 단계에서는 모든 과를 비교하지만, 속과 종 단계에서는 같은 부모를 가진 분류군끼리만 비교한다.

과 f 의 확률은

$$P(f | x) = \frac{\exp z_{F,f}}{\sum_{f'} \exp z_{F,f'}}$$

로 계산한다. 속 g 의 부모 과를 $\phi(g)$ 라 하면,

$$P(g | \phi(g), x) = \frac{\exp z_{G,g}}{\sum_{g': \phi(g')=\phi(g)} \exp z_{G,g'}}$$

이다. 마찬가지로 종 c 의 부모 속을 $\gamma(c)$ 라 하면,

$$P(c \mid \gamma(c), x) = \frac{\exp z_{S,c}}{\sum_{c': \gamma(c')=\gamma(c)} \exp z_{S,c'}}$$

로 계산한다.

종 c 의 최종 확률은 해당 종에 이르는 과-속-종 경로의 확률을 곱하여

$$P(c \mid x) = P(f(c) \mid x)P(g(c) \mid f(c), x)P(c \mid g(c), x)$$

로 정의한다. 따라서 종 단계의 점수뿐 아니라 상위 과와 속에서의 불확실성도 최종 종 확률에 함께 반영된다.

예를 들어 참느릅나무에 대해

$$P(\text{느릅나무과} \mid x) = 0.92, \quad P(\text{느릅나무속} \mid \text{느릅나무과}, x) = 0.85,$$

$$P(\text{참느릅나무} \mid \text{느릅나무속}, x) = 0.70$$

이라면,

$$P(\text{참느릅나무} \mid x) = 0.92 \times 0.85 \times 0.70 = 0.5474.$$

이와 같이 각 종의 확률은 하나의 분류 점수에서 직접 계산되는 것이 아니라, 분류 체계상의 경로를 따라 계산된다.

2.6 계층 모델의 학습 loss

앞 절에서 정의한 과, 속, 종의 조건부 확률을 그대로 학습에 사용한다. 표본 i 의 정답 종을 y_i , 그 종의 속과 과를 각각 g_i 와 f_i 라 하자. 각 단계의 loss는

$$\mathcal{L}_{F,i} = -\log P(f_i \mid x_i),$$

$$\mathcal{L}_{G,i} = -\log P(g_i \mid f_i, x_i),$$

$$\mathcal{L}_{S,i} = -\log P(y_i \mid g_i, x_i)$$

로 둔다. 따라서 한 표본의 분류의 loss는

$$\begin{aligned} \mathcal{L}_{\text{tax},i} &= \mathcal{L}_{F,i} + \mathcal{L}_{G,i} + \mathcal{L}_{S,i} \\ &= -\log P(f_i \mid x_i) - \log P(g_i \mid f_i, x_i) - \log P(y_i \mid g_i, x_i) \\ &= -\log P(y_i \mid x_i). \end{aligned}$$

즉 앞 절에서 정의한 과-속-종 경로 확률을 그대로 최대화하도록 학습한다. 부모 아래에 자식이 하나뿐이면 그 조건부 확률은 1이므로 해당 단계의 loss는 0이다.

계층적 prompt token에서는 같은 부모를 공유하는 잔차 벡터들의 평균이 0에 가깝도록 두

개의 항을 추가한다. 속 g 에 속한 종의 집합을 $\mathcal{C}_g$, 과 f 에 속한 속의 집합을 $\mathcal{G}_f$ 라 하자. 또한 둘 이상의 종을 가진 속의 집합을 $\mathcal{G}_{>1}$, 둘 이상의 속을 가진 과의 집합을 $\mathcal{F}_{>1}$ 이라 하면

$$\mathcal{L}_{\text{center},S} = \frac{1}{|\mathcal{G}_{>1}|} \sum_{g \in \mathcal{G}_{>1}} \frac{1}{L} \sum_{\ell=1}^L \left\| \frac{1}{|\mathcal{C}_g|} \sum_{c \in \mathcal{C}_g} \mathbf{s}_c^{(\ell)} \right\|_2^2,$$

$$\mathcal{L}_{\text{center},G} = \frac{1}{|\mathcal{F}_{>1}|} \sum_{f \in \mathcal{F}_{>1}} \frac{1}{L} \sum_{\ell=1}^L \left\| \frac{1}{|\mathcal{G}_f|} \sum_{g \in \mathcal{G}_f} \mathbf{r}_g^{(\ell)} \right\|_2^2.$$

자식이 하나뿐인 경우에는 평균을 계산할 다른 자식이 없으므로 이 항에서 제외한다.

최종 loss는

$$\mathcal{L}_{\text{total}} = \frac{1}{B} \sum_{i=1}^B \mathcal{L}_{\text{tax},i} + 0.001 \mathcal{L}_{\text{center},S} + 0.001 \mathcal{L}_{\text{center},G}$$

이다. 과, 속, 종의 세 분류 loss에는 모두 가중치 1을 사용하며, 0.001은 두 center loss에만 적용한다.

비교 모델의 명칭 이후 비교에서는 세 방법을 다음과 같이 구분한다.

Prompt-CAM은 taxonomy를 학습에 사용하지 않고 30개 종을 하나의 모델에서 prompt token 30개를 추가하여 직접 분류하는 Prompt-CAM을 뜻한다.

Independent Prompt-CAM은 Prompt-CAM 원논문에서 taxonomy를 다루기 위해 제시한 node별 학습 방식이다. 각 taxonomy node에서 그 node의 자식들을 구분하는 Prompt-CAM을 별도로 학습한다. WILD-30에서는 6개 과를 구분하는 root 모델, Ulmaceae 아래의 두 속을 구분하는 모델, 그리고 Quercus, Acer, Ulmus, Betula, Pinus 내부의 종을 구분하는 다섯 모델이 필요하므로 총 7개의 모델을 학습한다. 각 node가 서로 독립적으로 학습되므로 이 방법을 Independent Prompt-CAM이라 명명했다.

계층적 Prompt-CAM은 본 연구에서 제안하는 방법이다. 과, 속, 종의 프롬프트를 하나의 모델 안에서 함께 학습하며, 위의 과-속-종 경로 loss와 center loss를 동시에 적용한다.

2.7 Hierarchical Selective Classification

일반적인 분류 모델은 가장 높은 확률을 가진 종을 최종 예측으로 반환한다. 그러나 종 수준의 확률이 낮은 경우에도 모델이 그보다 상위의 분류군에 대해서는 충분히 확신할 수 있다. 예를 들어 참느릅나무와 다른 느릅나무속 종을 명확히 구분하지 못하더라도, 해당 이미지가 느릅나무속에 속한다는 판단에는 높은 확률을 줄 수 있다.

일반적인 selective classification에서는 예측의 신뢰도가 기준값보다 낮으면 해당 예측을 거부한다. Hierarchical Selective Classification(HSC)은 이 경우 예측 전체를 버리는 대신, 분류 체계에서 더 상위의 분류군을 반환한다 (Goren et al., 2024). 즉 종까지 확신할 수 있으면 종을 출력하고, 종은 불확실하지만 속까지는 확신할 수 있으면 속을 출력하며, 필요한 경우 과까지 올라간다. 이를 통해 예측의 정확성과 구체성 사이를 조절할 수 있다.

본 연구에서는 Goren et al. (Goren et al., 2024)이 제안한 Climbing 규칙을 사용한다. 먼저 가장 높은 확률을 가진 종을

$$\hat{c} = \arg \max_c P(c | x)$$

로 선택한다. 그다음 $\hat{c}$ 에서 시작하여 해당 종의 분류 경로를 따라 위쪽으로 이동한다. 분류군 v 아래에 속한 종의 집합을 $\mathcal{L}(v)$ 라 하면, v 의 확률은

$$P(v | x) = \sum_{c \in \mathcal{L}(v)} P(c | x)$$

로 계산한다. 따라서 종에서는 하나의 종 확률을 사용하고, 속에서는 그 속에 포함된 모든 종의 확률을 합하며, 과에서는 그 과에 포함된 모든 종의 확률을 합한다.

Climbing은 현재 분류군의 확률이 기준값 θ 이상인지 확인한다. 종 $\hat{c}$ 에 대해

$$P(\hat{c} | x) \geq \theta$$

이면 종을 그대로 반환한다. 그렇지 않으면 $\hat{c}$ 의 부모 속으로 올라가

$$P(g(\hat{c}) | x) = \sum_{c \in \mathcal{L}(g(\hat{c}))} P(c | x)$$

를 확인한다. 이 값도 θ 보다 작으면 다시 부모 과로 올라간다. 처음으로 확률이 θ 이상이 되는 분류군을 최종 예측으로 사용한다.

중요한 점은 Climbing이 모든 속이나 과를 새로 비교하는 방법이 아니라는 것이다. 처음 선택한 종 $\hat{c}$ 의 상위 경로만 따라 올라간다. 예를 들어 가장 높은 확률을 받은 종이 참느릅나무라면

$$\text{참느릅나무} \rightarrow \text{느릅나무속} \rightarrow \text{느릅나무과}$$

의 경로만 확인한다.

예를 들어

$$P(\text{참느릅나무} | x) = 0.55, \quad P(\text{느릅나무속} | x) = 0.88$$

이고 $\theta = 0.8$ 이라 하자. 참느릅나무의 확률은 0.8보다 작으므로 종 수준의 예측은 받아들이지 않는다. 그러나 부모인 느릅나무속의 확률은 0.88이므로 기준값을 넘는다. 따라서 최종 예측은 참느릅나무가 아니라 느릅나무속이 된다.

기준값 θ 는 최종 예측의 구체성을 조절한다. θ 가 낮으면 종 수준에서 예측이 멈추는 경우가 많아지고, θ 가 높아지면 더 높은 확률을 요구하므로 속이나 과를 반환하는 경우가 많아진다. 따라서 HSC에서는 단순히 종 예측의 정확도만 비교하는 것이 아니라, 정확성과 예측의 구체성을 함께 평가한다.

세 비교 모델에는 동일한 분류 트리, 동일한 θ , 동일한 Climbing 규칙을 적용한다. 차이는 Climbing에 입력되는 종 확률 $P(c | x)$ 을 각 모델이 어떻게 계산하는지에 있다.

Prompt-CAM은 30개 종을 직접 분류하여 얻은 종 확률을 사용한다. 상위 분류군의 확률은 그 아래 종들의 확률을 합하여 계산한다.

Independent Prompt-CAM은 Prompt-CAM 원논문에서 제시한 taxonomy 학습 방법에 따라 각 node의 분류 문제를 별도의 모델로 학습한다. 각 node에서 얻은 조건부 확률을 과·속·종 경로를 따라 곱하여 $P(c | x)$ 을 만든 뒤 Climbing을 적용한다.

계층적 Prompt-CAM은 본 연구에서 제안하는 하나의 공유 모델에서 과, 속, 종의 조건부 확률을 함께 계산하고, 앞 절에서 정의한 경로 확률 $P(c | x)$ 을 그대로 Climbing에 사용한다.

따라서 세 방법의 비교에서는 Climbing 규칙 자체는 동일하게 유지하고, 각 모델이 계산한 종 확률의 차이만 비교한다.

3 실험 및 결과

3.1 실험 설정

Wild-30은 학습 9,000장, 검증 1,500장, 테스트 1,500장으로 구성하였으며, 테스트 세트는 종마다 50장으로 균형화하였다. 모든 모델은 DINOv2 ViT-B/14와 336×336 입력을 사용하였다. 60 에폭 동안 SGD로 학습하였으며, 학습률은 0.001, 배치 크기는 32, 난수 시드는 42로 설정하였다. HSC 비교에 사용하는 확률은 세 모델 모두 bfloat16에서 다시 계산하였다.

비교 대상은 세 가지이다. **Prompt-CAM**은 taxonomy를 학습에 사용하지 않고 30개 종을 직접 분류한다. **Independent Prompt-CAM**은 Prompt-CAM 원논문에서 제시한 taxonomy 확장 방법으로, 각 내부 node의 자식들을 구분하는 Prompt-CAM을 별도의 모델로 학습한다 (Chowdhury et al., 2025). Wild-30에서는 전체 과를 구분하는 root 모델 1개, Ulmaceae 아래의 속을 구분하는 모델 1개, Quercus, Acer, Ulmus, Betula, Pinus 내부의 종을 구분하는 모델 5개가 필요하므로 총 7개의 모델을 학습한다. **계층적 Prompt-CAM**은 본 연구에서 제안하는 방법으로, 과·속·종 prompt token을 하나의 모델에서 함께 학습한다.

3.2 평가 지표

종 분류 성능은 Top-1 정확도로 평가하였다. Hierarchical Selective Classification(HSC)은 앞 절에서 정의한 Climbing을 사용하였으며, 성능은 hAURC로 비교하였다 (Goren et al., 2024). hAURC는 낮을수록 좋다. 모델 간 Climbing hAURC 차이는 종을 단위로 복원추출하는 10,000회 부트스트랩으로 평가하였다.

종 확률의 신뢰도를 비교하기 위해 NLL(Negative Log Likelihood), ECE(Expected Calibration Error)와 AUROC를 함께 계산하였다. AUROC는 최고 종 확률이 정답과 오답을 얼마나 잘 구분하는지를 나타낸다. NLL과 ECE는 낮을수록, AUROC는 높을수록 좋다.

3.3 분류 성능 및 계산 비용

세 모델의 종 Top-1 정확도는 80.40–81.07%로 비슷하였다. Independent Prompt-CAM이 81.07%로 가장 높았고, 계층적 Prompt-CAM은 80.73%, Prompt-CAM은 80.40%였다.

계산 비용에는 큰 차이가 있었다. Independent Prompt-CAM은 Wild-30의 전체 경로 확률을 계산하기 위해 7개의 모델과 이미지당 7회의 순전파가 필요하다. 반면 계층적 Prompt-CAM은 하나의 모델과 한 번의 순전파로 과·속·종의 결과를 모두 계산한다. 전체 학습 가능 파라미터 수는

Table 2: 세 모델의 중 Top-1 정확도.

모델	중 Top-1 (%)
Prompt-CAM	80.40
Independent Prompt-CAM	81.07
계층적 Prompt-CAM	80.73

Independent Prompt-CAM의 16,863,060 개에서 계층적 Prompt-CAM의 7,484,200 개로 감소하였다. 단일 NVIDIA L4에서 측정한 전체 실행 시간은 각각 9.87 GPU-h와 5.43 GPU-h였다.

Table 3: 세 모델의 계산 비용. 순전과 횟수는 한 이미지의 전체 예측을 얻는 데 필요한 횟수이다.

모델	모델 수	순전과 횟수	학습 가능 파라미터 수	GPU-h
Prompt-CAM	1	1	2,638,092	5.71
Independent Prompt-CAM	7	7	16,863,060	9.87
계층적 Prompt-CAM	1	1	7,484,200	5.43

따라서 Independent Prompt-CAM은 계층적 Prompt-CAM보다 약 $9.87/5.43 \simeq 1.82$ 배의 GPU 시간을 사용하였다. 두 방식의 가장 큰 차이는 여러 node별 모델을 따로 학습하고 추론하는 대신, 계층적 Prompt-CAM이 하나의 모델에서 전체 taxonomy를 처리한다는 점이다.

3.4 Hierarchical Selective Classification

세 모델에 동일한 분류 트리와 동일한 Climbing 규칙을 적용하였다. Climbing hAURC는 Prompt-CAM 32.355, Independent Prompt-CAM 29.612, 계층적 Prompt-CAM 31.378이었다. 세 모델 모두 중 확률이 기준값보다 낮을 때 바로 최상위 분류군으로 이동하는 일반 선택 규칙보다 Climbing에서 더 낮은 hAURC를 보였다.

Table 4: 세 모델의 HSC 결과. hAURC는 $\times 10^{-3}$ 단위이며 낮을수록 좋다.

모델	일반 선택 hAURC	Climbing hAURC
Prompt-CAM	43.794	32.355
Independent Prompt-CAM	37.930	29.612
계층적 Prompt-CAM	41.500	31.378

Independent Prompt-CAM의 점추정치가 가장 낮았지만, 세 쌍의 Climbing hAURC 차이에 대한 95% 부트스트랩 신뢰구간은 모두 0을 포함하였다. 따라서 현재 테스트 세트에서는 세 모델의 HSC 성능 차이가 통계적으로 명확하지 않았다.

신뢰도 진단 Independent Prompt-CAM은 NLL 0.7393, ECE 0.0738, AUROC 0.8674로 세 모델 가운데 가장 좋은 값을 보였다. 계층적 Prompt-CAM의 값은 각각 0.7920, 0.0969, 0.8535였다. 특히 오분류 이미지에서의 평균 최고 중 확률은 Independent Prompt-CAM이 0.6734, 계층적 Prompt-CAM이 0.7357이었다. 따라서 계층적 Prompt-CAM은 오답에서도 상대적으로 높은 중 확률을 부여하는 경향을 보였다.

Table 5: 종 단위 부트스트랩으로 계산한 Climbing hAURC 차이 ($\times 10^{-3}$).

비교	hAURC 차이	95% 신뢰구간
계층적 Prompt-CAM – Prompt-CAM	-1.167	[-6.022, 3.366]
Independent Prompt-CAM – Prompt-CAM	-2.397	[-7.766, 2.656]
계층적 Prompt-CAM – Independent Prompt-CAM	+1.229	[-3.033, 5.306]

Table 6: 전체 테스트 세트의 신뢰도 진단. NLL과 ECE는 낮을수록, 격차와 AUROC는 높을수록 좋다.

모델	속 Top-1 (%)	정답 속 확률	NLL	ECE	정답 신뢰도	오답 신뢰도	격차	AUROC
Prompt-CAM	93.93	0.9276	0.8968	0.1106	0.9432	0.7624	0.1808	0.8442
Independent Prompt-CAM	93.80	0.9287	0.7393	0.0738	0.9278	0.6734	0.2543	0.8674
계층적 Prompt-CAM	94.20	0.9325	0.7920	0.0969	0.9432	0.7357	0.2074	0.8535

3.5 Prompt-CAM의 분류 근거 검증

종 Prompt-CAM에서 높은 값을 받은 패치가 실제 종 분류에 사용되는지를 확인하기 위해 패치 제거 실험을 수행하였다. 계층적 Prompt-CAM이 정확히 분류한 이미지 가운데, 같은 속에 둘 이상의 종이 포함된 28개 종의 1,122장을 사용하였다. 각 이미지에서 종 Prompt-CAM 값이 높은 상위 10%의 패치 토큰을 선택하여 해당 이미지의 전체 패치 토큰 평균으로 대체하였다. 대조군에서는 같은 수의 패치를 무작위로 선택하였고, 이미지당 50회 반복한 평균 효과를 사용하였다. 신뢰구간은 종을 단위로 복원추출하는 10,000회 부트스트랩으로 계산하였다.

원본 이미지에서 정답 종 확률을 $p_i^{(0)}$, CAM 상위 패치 제거 후 확률을 $p_i^{(CAM)}$, 무작위 제거 후 확률을 $p_i^{(rand)}$ 라 하자. 두 제거 방식의 차이는

$$D_i = \left(p_i^{(0)} - p_i^{(CAM)} \right) - \left(p_i^{(0)} - p_i^{(rand)} \right)$$

로 계산하였다. $D_i > 0$ 이면 CAM 값이 높은 패치를 제거했을 때 정답 종 확률이 무작위 제거보다 더 크게 감소한다는 뜻이다.

CAM 상위 패치를 제거했을 때 정답 종 확률은 무작위 제거보다 평균 0.09045 더 감소하였으며, 95% 신뢰구간은 [0.07426, 0.10924]였다. 종 예측 변경률의 차이는 8.45%p, 정답 종과 가장 높은 경쟁 종 사이의 로그확률 차이 감소량의 차이는 1.5749였다. 세 지표 모두 신뢰구간이 0을 포함하지 않았다.

Table 7: 계층적 Prompt-CAM의 종 단계 패치 제거 실험. 차이는 CAM 상위 10% 패치 제거 효과에서 동일 개수의 무작위 패치 제거 효과를 뺀 값이다.

평가량	CAM 제거 – 무작위 제거	95% 신뢰구간
정답 종 확률 감소	0.09045	[0.07426, 0.10924]
종 예측 변경률	8.45%p	[6.62, 10.68]%p
정답 종-경쟁 종 로그확률 차이 감소	1.5749	[1.3577, 1.8021]

이 결과는 CAM 값이 높은 패치를 제거하면 같은 수의 무작위 패치를 제거한 경우보다 종 분류가 더 크게 약화된다는 것을 보여준다.

다른 모델과의 비교 세 모델이 모두 정확히 분류한 동일한 1,000개 이미지에서도 같은 실험을 수행하였다. 계층적 Prompt-CAM과 Prompt-CAM 사이에서는 종 예측 변경률과 로그확률 차이

감소 모두 명확한 차이가 확인되지 않았다.

Independent Prompt-CAM과의 비교에서는 종 예측 변경률 차이가 +2.01%p로 95% 신뢰구간이 0을 포함하였다. 반면 로그확률 차이 감소량은 계층적 Prompt-CAM이 0.5606 더 컸으며, 95% 신뢰구간은 [0.3350, 0.7761]이었다.

Table 8: 계층적 Prompt-CAM과 다른 모델의 종 CAM 제거 효과 비교. 양수는 계층적 Prompt-CAM의 제거 효과가 더 크다는 뜻이다.

비교	예측 변경률 차이	95% 신뢰구간	로그확률 차이 감소의 차이	95% 신뢰구간
계층적 Prompt-CAM - Prompt-CAM	-1.76%p	[-4.02, +0.47%p]	-0.169	[-0.433, +0.097]
계층적 Prompt-CAM - Independent Prompt-CAM	+2.01%p	[-0.29, +4.48%p]	+0.5606	[+0.3350, +0.7761]

CAM 값의 해석 CAM 값과 단일 패치 제거에 따른 점수 변화의 부호 사이의 Spearman 상관은 -0.0026이었지만, 점수 변화의 절댓값과 CAM 값의 상관은 0.4266이었다. 따라서 CAM은 해당 위치가 종 점수를 증가시키는 방향을 나타내기보다, 그 위치가 종 판별에 얼마나 중요한지를 나타내는 값으로 해석한다.

3.6 Prompt-CAM 정성적 시각화

그림 1은 동일한 참느릅나무 이미지에서 계층적 Prompt-CAM의 과, 속, 종 단계 CAM을 비교한다. 이 예에서는 세 분류 단계가 서로 다른 위치를 강조하였다.




Figure 1: 참느릅나무 동일 이미지에서 계층적 Prompt-CAM의 과, 속, 종 단계별 상위 4개 head. 왼쪽은 원본 이미지이며, 각 행은 해당 분류 단계에서 저장된 head별 CAM overlay이다.

그림 2은 동일한 상수리나무 이미지에서 Prompt-CAM, Independent Prompt-CAM, 계층적 Prompt-CAM의 종 단계 CAM을 비교한다. 세 모델이 강조하는 위치와 head는 서로 달랐다. 이 그림은 모델 간 차이를 보여주는 예시이며, CAM이 실제 분류에 사용되는 정도는 앞의 패치 제거 실험을 기준으로 판단한다.




Figure 2: 상수리나무 동일 이미지에서 세 모델의 중 단계 Prompt-CAM 비교. 각 행은 Prompt-CAM, Independent Prompt-CAM, 계층적 Prompt-CAM에서 저장된 상위 4개 head를 나타낸다.

4 논의

4.1 주요 결과

세 모델의 중 Top-1 정확도는 1%p 이내에서 비슷하였고, Climbing hAURC의 쌍별 차이도 통계적으로 명확하지 않았다. 따라서 계층적 Prompt-CAM은 Independent Prompt-CAM과 비슷한 분류 성능과 HSC 성능을 유지하였다.

반면 계산 구조에는 분명한 차이가 있었다. Prompt-CAM 원논문의 taxonomy 확장 방식인 Independent Prompt-CAM은 Wild-30에서 7개의 모델을 따로 학습하고 이미지당 7회의 순전파를 수행해야 한다 (Chowdhury et al., 2025). 계층적 Prompt-CAM은 이를 하나의 모델과 한 번의 순전파로 통합하였다. 실제 단일 NVIDIA L4 실행에서도 GPU 시간은 9.87 GPU-h에서 5.43 GPU-h로 감소하였다.

또한 계층적 Prompt-CAM은 한 이미지에 대해 과, 속, 중 단계의 CAM을 각각 계산한다. 중 CAM의 상위 패치를 제거했을 때 무작위 패치 제거보다 정답 중 확률, 중 예측, 정답 중과 경쟁 중 사이의 로그확률 차이가 모두 더 크게 감소하였다. 따라서 적어도 중 단계에서는 CAM 값이 높은 위치가 실제 분류 계산에 중요하게 사용되고 있음을 확인하였다.

본 연구의 주된 결과는 최고 정확도를 높였다는 데 있지 않다. 원논문에서 여러 node별 Prompt-CAM으로 나누어 처리하던 taxonomy를 하나의 모델로 통합하면서 분류 성능을 거의 유지하고, 동시에 과·속·중 단계의 분류 근거를 각각 확인할 수 있도록 했다는 데 있다.

4.2 한계

첫째, 과·속·중 단계의 Prompt-CAM을 각각 계산할 수 있음을 보였지만, 각 CAM이 실제 생물 분류학적 진단 형질과 일치하는지는 전문가 주석으로 검증하지 않았다. 따라서 현재 CAM은 각 분류 단계에서 모델이 사용한 이미지 위치를 보여주는 것으로 해석한다.

둘째, 실험은 30종, 7속, 6과로 구성된 Wild-30에 한정되어 있다. 더 많은 종과 더 깊은 taxonomy에서도 하나의 공유 모델이 Independent Prompt-CAM과 비슷한 성능을 유지하는지는 추가 검증이 필요하다.

셋째, 계층적 Prompt-CAM은 중 표현을 과 수준의 공통 표현, 속 수준의 residual, 중 수준의 residual로 구성한다. 그러나 실제 시각적 유사성이 항상 생물분류학적 계층과 같은 방식으로 나뉜다고 보장할 수는 없다. 분류학적으로 먼 종이 시각적으로 비슷하거나, 가까운 종이 시각적으로 매우 다른 경우를 더 잘 다룰 수 있는 계층 표현은 이후 연구가 필요하다.

References

- Jia, M. et al. (2022). Visual Prompt Tuning. *European Conference on Computer Vision (ECCV)*.
- Chowdhury, A. et al. (2025). Prompt-CAM: Making Vision Transformers Interpretable for Fine-Grained Analysis. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 4375–4385.
- Goren, S., Galil, I., and El-Yaniv, R. (2024). Hierarchical Selective Classification. *Advances in Neural Information Processing Systems 37 (NeurIPS 2024)*.